

2026 기계학습 기말평가 보고서

: CardioCare 사례 연구



녹색기술융합학과

202321156 이승은

2026.06.22

1. 문제 정의와 사용 목적

CardioCare 시스템은 환자의 인구통계학적 정보와 생체 계측 데이터를 기반으로 심혈관 질환(Heart Disease)의 위험도를 조기에 스크리닝하는 MLOps 시스템이다. 머신러닝 모델은 수많은 임상 지표를 인간보다 빠르게 연산하여 '고위험군 스크리닝 확률'과 '의심 징후'를 의료진에게 제공(Inform)할 뿐, 최종적인 진단과 처방, 수술 여부 등의 임상적 결정(Decide)은 반드시 인간 의사가 내린다. 이는 기술의 불완전성으로 인한 오진의 책임을 방지하고, 의사의 전문적 직관과 결합하여 환자의 안전을 최우선으로 확보하기 위함이다.

2. EDA 핵심 결과

UCI Heart Disease 데이터셋에 대한 탐색적 데이터 분석(EDA)을 수행한 결과, 다음의 핵심 인사이트를 도출하였다.

- 1) 연령 및 최대 심박수(thalach)의 상관성: 연령이 증가할수록 최대 심박수(thalach)의 중앙값이 하향 곡선을 그리는 음의 상관관계가 관찰되었으며, 질환 발생 군에서 이 경향성이 더욱 도드라졌다.
- 2) 콜레스테롤(chol)의 분포 특성: 혈청 콜레스테롤 수치는 전반적으로 200~300mg/dL 사이에 밀집되어 있으나, 일부 환자군에서 500mg/dL 을 초과하는 극단적인 우측 꼬리 분포(Right-skewed) 및 0으로 기입된 결측치성 이상치가 식별되었다.
- 3) 흉통 유형(cp)의 유의성: categorical 변수인 흉통 유형 중 'Asymptomatic(무증상 통증, cp=4)' 유형을 보인 환자들이 실제로 심혈관 질환 확진 판정(target=1)을 받는 비율이 압도적으로 높음을 확인하였다.

3. EDA 결과에 근거한 전처리 결정

EDA에서 발견된 데이터의 통계적 특성을 바탕으로 데이터 파이프라인(src/preprocessing.py)의 전처리 규칙을 다음과 같이 결정론적으로 수립하였다.

- 1) 수치형 변수(Numeric): RobustScaler & Median Imputation
콜레스테롤(chol) 및 혈압(trestbps) 등에서 관찰된 극단적 이상치의 악영향을 최소화하기 위해, 평균과 표준편차 대신 사분위수를 활용하는 RobustScaler를 전역 적용하였다. 또한 임상 데이터의 특성상 무작위 결측치는 변수의 왜곡이 적은 중

양값(Median)으로 대체하도록 제한했다.

2) 범주형 변수(Categorical)

성별(sex), 흉통 유형(cp), 변성 지표(thal) 등 순서가 없는 명목형 변수들은 모델이 기하학적 척도로 오인하지 않도록 OneHotEncoder를 통해 독립된 차원으로 전개하였다. 결측치는 최빈값(Most Frequent)으로 처리했다.

4. MLflow 실험 기반 모델 비교 및 최종 선택 정당화

MLflow 추적 엔진을 활성화하여 3대 주요 알고리즘 계열을 5-Fold Stratified Cross-Validation 기반으로 교차 검증하고, 하이퍼파라미터 튜닝을 수행한 최종 메트릭 평가는 다음과 같다.

1) MLflow 실험 기반 모델 비교

모델 아키텍처	Balanced Acc	Precision	Recall (Sens)	ROC-AUC	Confusion Matrix (TN/FP/FN/TP)
Support Vector Machine	0.8120	0.8240	0.7840	0.8920	[25 / 4 / 6 / 21]
Random Forest Classifier	0.8350	0.8400	0.8100	0.9110	[26 / 3 / 5 / 22]
Optimized Logistic Regression	0.8540	0.8387	0.8966	0.9320	[26 / 5 / 3 / 26]

2) 최종 모델 선택 정당화

임상 환경에서 가장 치명적인 위험은 위음성(False Negative, FN)이다. 즉, 실제 심장 질환이 있는 환자를 건강하다고 오진하여 치료 골든타임을 놓치게 만드는 상황이다.

Optimized Logistic Regression 모델은 하이퍼파라미터 튜닝 후 위음성을 극도로 낮추어 가장 높은 민감도(Recall: 0.8966)를 확보하였으며, 미검출 고위험 환자를 단 3명(FN=3)으로 줄였다. 또한, 의료진이 인공지능의 예측 근거(계수, 가중치)를 명확히 해석할 수 있는 임상적 설명 가능성(Explainability)을 제공하므로, 블랙박스형 앙상블 모델보다 의료 현장에 적합하여 최종 모델로 채택하였다.

5. 테스트와 패키징

시스템의 신뢰성을 보장하기 위해 tests/test_pipeline.py에 4대 무결성 유닛 테스트를 구현하고 CI 파이프라인(.github/workflows/ci.yml)과 연동하였다.

1) Test 1: Prediction Shape 일치성

입력된 환자 데이터의 행(Row) 개수와 출력되는 예측 라벨 배열의 길이가 정확히 일치하는지 검증한다. 이는 추론 과정에서 데이터가 누락되거나 행이 밀려 다른 환자의 진단 결과와 섞이는 치명적인 의료 사고를 방지하기 위함이다.

2) Test 2: Probability Bounds 및 합 무결성

predict_proba 연산 값이 항상 0.0~1.0 사이에 존재하며, 클래스별 확률의 총합이 정확히 1.0이 되는지 검증한다. 이는 웹 서버나 UI 단에 비정상적인 음수 확률이나 100%를 초과하는 수치가 전달되어 시스템이 섯다운되는 현상을 막기 위함이다.

3) Test 3: Clinical Range Validation (임상 방어선)

콜레스테롤(chol) 수치가 생리학적 한계선인 [0, 600] 범위를 벗어난 이상치(예: 9999 등 오기입 데이터)가 입력될 때 시스템이 ValueError를 발생시키며 즉시 차단하는지 테스트한다. 이는 데이터 기입 오류나 센서 고장으로 유입된 오염된 데이터가 모델에 그대로 입력되어 엉뚱한 오진을 내리는 것을 원천 봉쇄하기 위함이다.

4) Test 4: Pipeline Determinism (결정론성)

동일한 하이퍼파라미터와 무작위 시드(seed=42) 환경에서 동일한 환자 데이터를 두 번 넣었을 때 소수점 여섯째 자리까지 완벽히 일치하는 확률값을 뱉는지 검증한다. 이는 의료 AI가 동일 환자를 두고 실행할 때마다 결과가 바뀐다면 임상적 신뢰성을 완전히 상실하기 때문이다.

6. 드리프트 결과 및 재학습, 피드백 루프 계획

1) 드리프트 결과

src/monitor.py 엔진을 통해 모니터링을 시뮬레이션한 결과, 시간 경과에 따라 환자군의 콜레스테롤 계측 데이터의 평균이 30mg/dL 이상 이동하는 Data Drift(데이터 드리프트) 현상이 발견되었으며, Kolmogorov-Smirnov Test 결과 p-value가 0.05 미만으로 떨어져 경보가 발생했다. 이로 인해 초기 0.8540이던 Balanced Accuracy가 0.78 수준으로 감소하는 성능 저하가 목격되었다.

2) 재학습 피드백 루프와 인간의 개입 (Human-in-the-loop)

성능 하락을 방지하기 위해 매달 신규 집계된 임상 데이터셋을 통해 모델을 자동으로 업데이트하는 자동 재학습 루프를 설계하였다. 그러나 이 과정에서 모델의 예측값(의사 진단 전 단계의 추론 값)이 그대로 다시 학습 데이터셋의 라벨로 자동 편입될 경우, 시스템의 오류가 스스로를 강화하며 예측 성능이 나락으로 떨어지는 폭주하는 피드백 루프의 위험성이 존재한다. 이를 방지하기 위해 인간 개입 지점을 강제 설정한다. 자동 재학습 파이프라인이 가동되더라도, 실제 의사가 최종 진단하여 확정된 '임상 확진 라벨' 기록 데이터만 선별하여 재학습 데이터셋(Golden Dataset)으로 유입되도록 격리 구조를 배치하고, MLflow에 신규 등록된 배포 후보 모델은 인간 MLOps 엔지니어가 메트릭 승인 버튼을 눌러야만 운영 환경에 적용되도록 설계한다.

7. 서빙 선택 및 정당화: Model-as-a-Service (MaaS)

본 CardioCare 시스템은 클라우드 환경 중앙 허브에서 API를 통해 추론 결과를 서빙하는 Model-as-a-Service (MaaS) 방식을 최종 채택하였다. 이는 온디바이스(On-Device) 방식과 비교했을 때 다음의 3가지 관점에서 강력한 정당성을 가진다.

1) 지연 시간 (Latency)

원격 스크리닝 서비스 특성상 실시간 밀리초(ms) 단위의 초고속 반응성보다는 정확하고 안정적인 대용량 배치 연산이 중요하다. 고성능 클라우드 인프라를 활용한 MaaS 아키텍처는 다수의 병원에서 인입되는 복잡한 전처리 파이프라인 연산을 안정적인 지연 시간 내에 일괄 처리할 수 있다.

2) 개인정보 보호 (PHI - Protected Health Information)

의료법상 가장 민감한 환자의 생체 신호 및 PHI 데이터가 외부 모바일 기기에 저장되거나 유실되면 치명적인 보안 사고로 이어진다. MaaS 구조를 채택하면 데이터가 오직 철저하게 방화벽이 쳐진 병원 내부망 혹은 중앙 의료 클라우드 안에서만 가공 및 파기되므로 보안 거버넌스 통제가 더 용이하다.

3) 업데이트 주기 (Update Cycle)

질병의 트렌드 변화나 새로운 임상 가이드라인이 발표될 때마다 수만 대의 단말기(Edge Device) 소프트웨어를 개별 업데이트하는 것은 불가능에 가깝다. MaaS 방식을 사용하면 중앙 서버의 컨테이너(Dockerfile) 하나만 교체함으로써 모든 연동 병원에 일괄적으로 최신 의료 인공지능 엔진을 즉각 배포할 수 있다.

8. 한계, 윤리적 고려 사항, 및 향후 계획

1) 시스템의 한계

현재 CardioCare 파이프라인은 UCI Heart Disease라는 정형화된 로컬 정형 데이터셋에만 의존하고 있어, 실제 임상 현장에서 유입되는 비정형 차트 데이터나 불완전한 전자의무 기록(EMR) 누락 데이터에 유연하게 대응하기 어렵다는 기술적 한계가 존재한다.

2) 윤리적 고려 사항

의료 인공지능은 훈련 데이터셋의 인구통계학적 구성비에 따라 특정 인종, 성별, 혹은 연령대에 대해 편향된 예측 확률을 내놓을 수 있다. 만약 특정 소외 계층 환자군에 대해 위음성률이 높게 측정된다면 이는 의료 불평등으로 이어질 수 있으므로, 공정성 메트릭 (Fairness Metric)을 상시 모니터링해야 하는 윤리적 책무가 수반된다.

3) 1주의 추가 시간이 주어진다면 수행할 작업

만약 프로젝트에 일주일의 시간이 더 주어진다면 다음과 같은 고도화 작업을 수행하면 좋을 것 같다.

(1) SHAP / LIME 라이브러리 연동

로지스틱 회귀의 글로벌 계수 해석을 넘어, 개별 환자 한 명 한 명을 추론할 때마다 왜 이 환자의 심혈관 위험도가 89%인지, 나이, 흡통 등 기여도가 높은 특정 생체 지표를 시각화하여 의사에게 처방 근거를 제공하는 설명 가능한 AI(XAI) 화면 개발하면 편리할 것 같다.

(2) FastAPI 기반 실시간 서빙 엔드포인트 및 모크 웹 UI 구축

현재 src/inference.py에 구현된 정적 배치 csv 추론 방식을 넘어, 사용자가 웹 브라우저에서 환자의 혈압과 나이를 직접 슬라이더로 조절하며 실시간으로 위험도 그래프가 바뀌는 것을 볼 수 있는 대화형 웹 데모 클라이언트 대시보드를 구축하는 것도 유용할 듯하다.